

Unified TMIL: Phát hiện Lừa đảo Ethereum

Mức Tài khoản & Mức Giao dịch trong Một Lướt Truyền xuôi

Giữ nguyên BERT4ETH + TMIL, kèm Benchmark được Kiểm toán và một Nghiên cứu Định vị Trung thực

Bản nộp ẩn danh

- 1 Bài toán & Động lực
- 2 Baseline & Điểm yếu
- 3 Hướng đi & Thay đổi cốt lõi
- 4 Dataset
- 5 Kiến trúc
- 6 Kết quả: Mức Tài khoản
- 7 Kết quả: Định vị
- 8 Các Ablation
- 9 Thảo luận

- Lừa đảo on-chain rút **hàng trăm triệu USD** mỗi năm (address poisoning, ice-phishing approvals, lệnh Seaport/NFT độc hại).
- Hai câu hỏi, thường được giải *riêng rẽ*:
 - **Mức tài khoản** — địa chỉ này có phải kẻ lừa đảo?
 - **Mức giao dịch** — *giao dịch* nào mới là giao dịch gian lận?
- Hiếm khi giải bằng **một mô hình**, và hiếm khi đủ **độ chặt chẽ đánh giá** để tin các tập dữ liệu crypto nhỏ, bị tái sử dụng.

Mục tiêu (cố tình ràng buộc): giữ nguyên backbone đã công bố, và cho thấy *hợp nhất cẩn thận* + một *giao thức trung thực* đi xa đến đâu.

- Transformer tiền-huấn-luyện cho phát hiện gian lận Ethereum.
- Mỗi giao dịch → embedding: **đối tác, hướng IN/OUT, số tiền, đếm, vị trí/thời gian**, rồi bộ mã hóa Transformer.
- Biểu diễn **mức tài khoản** mạnh; **không có định vị mức giao dịch**.

- Góc nhìn Multiple-Instance Learning: **1 tài khoản = 1 túi** giao dịch.
- Pipeline: **TCN** → **Gated-Attention MIL** → **Bag Aggregation** → **MLP**.
- Trọng số attention $\Rightarrow$ định vị ứng viên.
- **Hạn chế chính:** C-TMIL *che cứng inbound* và chỉ attend *outbound*.

- **Mặt nạ cứng chỉ-outbound** vớt bỏ tín hiệu inbound — nhưng approve/permit/ice-phishing được kích hoạt từ *inbound* (cú rút là một transferFrom).
- **Hai mức độ, hai mô hình** — không có hệ thống hợp nhất duy nhất.
- **Giả định “attention = giải thích”** — chưa bao giờ được kiểm chứng.
- **Lỗi hổng đánh giá:** thiếu mẫu âm khó, thiếu CI, thiếu OOD, GT định vị đơn nhãn, các ca qua hợp đồng chưa gán nhãn.

Ràng buộc tuân thủ:

- Embedding BERT4ETH (đối-tác+IN/OUT+số-tiền+đếm+vị-trí) — **không đổi**.
- TMIL (TCN → Gated-Attn MIL → Bag Agg → MLP) — **không đổi**.
- Không backbone mới, không đầu định vị mới.

Thay đổi cốt lõi:

- Thay *mặt nạ cứng chỉ-outbound* của C-TMIL bằng *embedding IN/OUT sẵn có* của BERT4ETH.
- Để mô hình **tự học** inbound hay outbound mới quan trọng, thay vì giả định.

- ❶ **Mô hình hợp nhất thực sự, một-bộ-trọng-số:** một bộ mã hóa dùng chung, hai đầu attention, *một lượt truyền xuôi* → quyết định tài khoản + xếp hạng giao dịch.
- ❷ **Benchmark kiểm toán + giao thức gán nhãn lại qua hợp đồng:** truy vết biên lai thực thi (transferFrom, Seaport OrderFulfilled, ETH nội bộ); GT sạch 83.4% → 92.7%.
- ❸ **Đánh giá trung thực:** CI bootstrap cụm, âm theo nguồn, phân tầng hoạt động, phép chia OOD, và ablation cho thấy attention *có thể* được huấn luyện để định vị nhưng bị **đặc trưng thủ công thâm tóm** trong hợp nhất.


- **Huấn luyện (nội miền):** tập phishing + EOA bình thường của BERT4ETH (11.136 túi train; vocab 84.982 token).
- **Kiểm thử — mức tài khoản (chéo miền):** tài khoản cashier/recipient kẻ lừa đảo PTXPhish so với tài khoản lành tính.
- **Kiểm thử — mức giao dịch:** các hash giao dịch PTXPhish.
- **Lịch sử** crawl qua **Etherscan**; mô hình chỉ huấn luyện trên dữ liệu nội miền $\Rightarrow$ PTXPhish là **zero-shot**.

Tập con	Số lượng
Giao dịch phishing đã kiểm toán (PTXPhish)	4998
GT sạch chuyển-trực-tiếp	4168 (83.4%)
+truy-vết-biên-lai (Seaport/NFT/transferFrom)	+466
tổng GT mức tài khoản sạch	4634 (92.7%)
EOA kẻ lừa đảo duy nhất (mẫu dương)	292
poisoning / payable / ice_phishing	188 / 59 / 45
Mẫu âm khó (PTXPhish lành tính, KOL/DeFi)	80
Mẫu âm EOA Bình thường giữ lại	1324
Túi định vị GT-nội-vùng	101

- **Phishing chuyển trực tiếp:** hash PTXPhish *chính là* mục tiêu định vị (nằm trong lịch sử) — 83.4%.
- **Qua hợp đồng** (Approve, Permit, Seaport, NFT order): hash được liệt kê là một phê duyệt nạn nhân / lời gọi sàn. Dịch chuyển giá trị nằm trong một *biên lai thực thi*.
- Chúng tôi **truy vết** transferFrom ERC-20/WETH, Seaport OrderFulfilled, ETH nội bộ → quy kết EOA kẻ lừa đảo và **gán nhãn lại giao dịch thực thi**.
- GT mức tài khoản sạch: **83.4%** → **92.7%** (94.8% nếu loại hạ tầng nâng cấp proxy).

- **1 tài khoản Ethereum = 1 túi.**
- **Cửa sổ cố định** $L=100$ giao dịch ($>90\%$ EOA kẻ lừa đảo có $< L$ tx sau mốc neo).
- Cửa sổ đơn tránh sự mơ hồ tổng hợp điểm của các cửa sổ trượt chồng lẫn.
- Cửa sổ dương kết thúc tại **mốc phát hiện** $\Rightarrow$ recency thành prior mạnh (xử lý sau).
- Loại giao dịch *cuối* của mỗi túi khởi ứng viên & GT cho **mọi** phương pháp (trung hòa tạo tác tx-cuối tầm thường).

Kiến trúc Unified TMIL



- **Bộ mã hóa dùng chung:** embedding BERT4ETH mỗi tx (đối-tác/IN-OUT/số-tiền/đếm/thời-gian) $\rightarrow$ LayerNorm $\rightarrow$ **TCN**.
- **Head-C** (gated-attention mềm): gộp túi $\rightarrow$ BCE **tài khoản**.
- **Head-L:** xếp hạng giao dịch để **định vị**; dùng *embedding IN/OUT* thay mặt nạ cứng, huấn luyện đồng thời dưới BCE.
- Một bộ trọng số, **một lượt truyền xuôi**.
- Mất mát: $\mathcal{L} = \text{BCE}(C) + \lambda \text{BCE}(L) + \beta \mathcal{L}_{\text{contrast}}$.
- **Phát hiện:** đọc hậu kỳ từ đầu mềm là *không đủ* — Head-L phải nhận gradient.

So sánh mức tài khoản (chéo miền zero-shot)


Phương pháp	ID-F1	ID-AUC	X-AUC	X-AUC _{kh}
BERT4ETH	0.734	0.925	0.989	0.836
ZipZap	0.711	0.915	0.979	0.776
TSGN	0.727	0.918	0.985	0.760
LMAE4Eth	0.750	0.933	0.980	0.708
Max-pool MIL	0.752	0.933	0.978	0.779
Gated-attn MIL	0.733	0.922	0.965	0.803
Mean-pool MIL	0.755	0.933	0.957	0.885
Unified TMIL (của chúng tôi)	0.735	0.922	0.984	0.725

X-AUC tổng hợp **0.984**; tập con khó 0.725, CI [0.658, 0.791]. *Cạnh tranh và là phương pháp duy nhất còn định vị được; đóng góp là **hợp nhất**, không phải SOTA tài khoản mới.*

Phương pháp	Precision	Recall	F1
BERT4ETH	0.749	0.722	0.734
ZipZap	0.737	0.687	0.711
TSGN	0.722	0.733	0.727
LMAE4Eth	0.736	0.765	0.750
Gated-attn MIL	0.736	0.721	0.728
TransMIL	0.719	0.745	0.729
CLAM	0.729	0.721	0.724
Unified TMIL (của chúng tôi)	0.709	0.766	0.735

Ngưỡng 0.5, trung bình 3 seed (std của chúng tôi: $P \pm .028$, $R \pm .040$, $F1 \pm .011$). F1 cạnh tranh và **recall cao nhất** trong nhóm đã công bố — và là mô hình duy nhất còn định vị được.


AUC theo nguồn mẫu âm & mức hoạt động



#tx	#âm	#dương	AUC
3-20	1218	54	0.999
20-100	104	103	0.971
100+	76	130	0.741

Tín hiệu duy trì ở tầng hoạt-động-cao — không chỉ là “power-user vs. tài khoản gần ngày”.

Khái quát hóa ngoài-phân-phối (OOD)




Phân vùng OOD	AUC	AUPR
payable_function	0.998	0.894
ice_phishing	0.967	0.316
address_poisoning	0.984	0.765
sớm (train)	0.985	0.802
muộn (test)	0.983	0.763

Duy trì qua chéo cơ chế (giữ lại một loại) và theo thời gian.

Bộ xếp hạng	Hit@1	Hit@5	Hit@10	MRR
Amount-rank	0.347	0.584	0.663	0.447
Degree-rank	0.465	0.772	0.822	0.607
Novelty-rank	0.356	0.782	0.832	0.551
Recency-rank	0.693	0.921	0.931	0.799
Gated-attn MIL	0.446	0.752	0.881	0.598
TransMIL	0.406	0.673	0.792	0.533
CLAM	0.455	0.792	0.871	0.599
Head-L chỉ-attention	0.416	0.752	0.891	0.576
Head-L (mạnh: sharpen+inst)	0.515	0.851	0.921	0.646
Hợp nhất nhận biết nội dung	0.832	0.931	0.941	0.880

Hợp nhất nhận biết nội dung vượt recency ở Hit@1: $+0.139$, paired bootstrap $p=0.002$.

Attention CÓ THỂ huấn luyện để định vị — nhưng bị thu tóm trong hợp nhất



Biến thể	Hit@1	MRR
Head-L chỉ-attention (gốc)	0.416	0.576
Head-L chỉ-attention (mạnh)	0.515	0.646
Hợp nhất (+attn gốc)	0.832	0.880
Hợp nhất (+attn mạnh)	0.782	0.848
Hợp nhất (−attn)	0.792	0.860

Hai mắt mắt weakly-supervised nâng Hit@1 chỉ-attention **0.416→0.515 (+24%)**. Nhưng trong hợp nhất, attn mạnh **không** thắng không-attn (0.782 vs 0.792, paired $p=0.68$): đặc trưng thủ công đặt trần.

Ablation backbone (chuyển giao mức tài khoản)

Biến thể	ID-F1	X-AUC	X-AUC_{kh}
Mô hình đầy đủ	0.734	0.974	0.849
– bộ mã hóa TCN	0.735	0.955	0.592
– embedding đối tác	0.554	0.960	0.461
– embedding IN/OUT	0.717	0.928	0.662
$\lambda=0$ (chỉ mềm)	0.733	0.965	0.803
$\lambda=0.25$	0.735	0.969	0.837

Embedding đối tác + IN/OUT dẫn dắt chuyển giao âm-khó $\Rightarrow$ biện minh thay mặt nạ outbound bằng embedding IN/OUT. Head-L đồng thời ($\lambda>0$) không hại tài khoản.

- **Mặt nạ outbound vs. embedding IN/OUT:** embedding IN/OUT khôi phục AUC âm-khó ($0.662 \rightarrow 0.849$); hướng học được $>$ chỉ-outbound giả định.
- **Đặc trưng payload BẬT/TẮT:** đặc trưng on-chain/payload thủ công mới *dẫn dắt* định vị (Hit@1 $0.41 \rightarrow 0.83$).
- **Chỉ-attention vs. có trợ giúp đặc trưng:** chỉ-attention $0.416 \rightarrow 0.515$ (huấn luyện được) nhưng đặc trưng đặt trần trong hợp nhất (mạnh vs không-attn $p=0.68$).

- **Bể mẫu âm khó nhỏ** (80 DeFi/KOL): phương sai không nhỏ $\Rightarrow$ báo cáo CI bootstrap cụm. Giữ nguyên PTXPhish để so sánh được.
- **Thiên lệch vị trí**: cửa sổ dương kết thúc tại mốc phát hiện $\Rightarrow$ recency mạnh; trung hòa tx-cuối tầm thường và đo so với recency.
- **Attention là tín hiệu hữu ích nhưng không thiết yếu** cho định vị; đặc trưng thủ công đặt trần (ablation của chúng tôi).
- **Độ phủ**: GT sạch 92.7%; hạ tầng nâng cấp proxy để dành truy vết tương lai.
- Mô hình tài khoản *cạnh tranh, không phải SOTA tuyệt đối* — theo thiết kế.

- **Unified TMIL:** phát hiện phishing tài khoản + giao dịch trong *một lượt truyền xuôi*, giữ nguyên BERT4ETH và TMIL.
- **Yếu tố mở đường:** thay mặt nạ cứng chỉ-outbound bằng **embedding IN/OUT** học được.
- **Đóng góp benchmark:** PTXPhish kiểm toán + giao thức gán nhãn lại qua hợp đồng.
- **Định vị đạt SOTA trên benchmark này:** bộ xếp hạng nhận-biết-nội-dung thắng mọi baseline MIL/heuristic (0.832 vs recency 0.693, $p=0.002$). Attention hữu ích nhưng không thiết yếu.
- Chúng tôi công bố benchmark, giao thức, baseline và mã đánh giá.

Cảm ơn — câu hỏi?